

12. Параллельная обработка

Сухорослов Олег Викторович

02.12.2024

План лекции

- Параллельные вычисления
- Параллельная обработка запросов
- Параллельная обработка данных

Параллельные вычисления

Параллельные вычисления: Зачем?


Использование нескольких процессоров для

- решения задачи за меньшее время
- решения бОльших задач, чем на одном процессоре

Специфика параллельных вычислений




Примеры задач



Large-scale models by domain and publication date

 EPOCH AI

Training compute (FLOP)



Параллельные вычисления: Как?

- Создание параллельного алгоритма
 - Поиск параллелизма в последовательном алгоритме, модификация или создание нового алгоритма
 - Декомпозиция исходной задачи на подзадачи, которые могут выполняться одновременно
 - Анализ зависимостей между подзадачами
- Реализация параллельного алгоритма
 - Распределение подзадач между исполнителями (процессорами, узлами...)
 - Организация взаимодействия между подзадачами
 - Учет архитектуры целевой параллельной системы
 - Запуск, измерение и анализ показателей эффективности

Классы параллельных систем

- Single Instruction, Multiple Data (SIMD)
 - SIMD-инструкции CPU
 - Графические процессоры (GPU)
- Multiple Instruction, Multiple Data (MIMD)
 - Системы с общей памятью
 - Системы с распределенной памятью
 - Гибридные системы
- Современные системы сочетают в себе оба класса

Массивно-параллельная система (МРР)




Beowulf Cluster (1990-e)



Современный НРС-кластер



Специализированные системы



<https://www.semianalysis.com/p/tpuv5e-the-new-benchmark-in-cost>

Показатели эффективности

- Ускорение (speedup)

$$S_p(n) = \frac{T_1(n)}{T_p(n)}$$



- Эффективность (efficiency)

$$E_p(n) = \frac{S_p(n)}{p} = \frac{T_1(n)}{p T_p(n)}$$

Ускорение

- $S = p$
 - Идеальный случай
- $S < p$
 - Последовательные (нераспараллеленные) части алгоритма
 - Накладные расходы: $T_p = \frac{T_1}{p} + T_{overhead}$
- $S > p$
 - Сверхлинейное ускорение
 - Рабочие данные помещаются в кэше, параллельный поиск

Типичные кривые



Закон Амдала

- Доля последовательных вычислений:

$$f = \frac{T_{seq}}{T_1}$$


- Время выполнения параллельной реализации:

$$T_p = fT_1 + \frac{(1-f)T_1}{p}$$



- Максимальное достижимое ускорение:

$$S_p = \frac{T_1}{T_p} = \frac{1}{f + \frac{1-f}{p}}, \quad \lim_{p \rightarrow \infty} S_p = \frac{1}{f}$$

Закон Амдала



Закон Амдала




Последовательные части

- Присутствуют изначально
 - Разные активности, которые нельзя распараллелить
 - Инициализация и завершение работы
 - Чтение входных данных и запись результатов
- Появляются в результате распараллеливания
 - Запуск исполнителей (потоков, процессов...)
 - Создание и распределение подзадач
 - Координация и синхронизация между исполнителями
 - Сбор и объединение результатов

Как быть?

- Закон Амдала: размер задачи зафиксирован, хотим как можно больше уменьшить время решения
- На практике при увеличении числа процессоров имеет смысл **увеличивать размер задачи**, оставляя время решения таким же
- Эффект Амдала: доля последовательных вычислений уменьшается при увеличении размера задачи
 - Умножение матриц: ввод/вывод $\sim n^2$, вычисления $\sim n^3$

Закон Густафсона-Барсиса



Gustafson J. [Reevaluating Amdahl's Law](#) (1988)

Масштабируемость

- Параллельная программа является **масштабируемой**, если при увеличении числа исполнителей можно сохранять значение эффективности
- **Сильная масштабируемость (strong scaling)** – эффективность сохраняется без необходимости увеличения размера задачи
- **Слабая масштабируемость (weak scaling)** – для поддержания заданной эффективности требуется увеличивать размер задачи пропорционально числу исполнителей

Параллельная обработка запросов


Техники горизонтального масштабирования

- Репликация stateless-сервиса + балансировка нагрузки
- Кэширование
- Разбиение stateful-сервиса по данным (шардинг)
- **Параллельная обработка**



Масштабирование тяжелых запросов

- Запрос требует проведения вычислений или чтения данных
- Объемы требуемых вычислений и данных растут
- Как обеспечить масштабируемость?

Параллельная обработка (Scatter/Gather)





Распределенный поиск (шардинг)



Выбор числа серверов?

- См. закон Амдала
- Фиксированные накладные расходы на обработку подзапросов
- Дополнительные накладные расходы на распаралелливание


Tail Latency



<https://robertovitillo.com/why-you-should-measure-tail-latencies/>

Tail Latency Amplification

- Время обработки запроса определяется самым медленным сервером
- С ростом числа серверов риск задержки увеличивается



	50%ile latency	95%ile latency	99%ile latency
One random leaf finishes	1ms	5ms	10ms
95% of all leaf requests finish	12ms	32ms	70ms
100% of all leaf requests finish	40ms	87ms	140ms

Dean J., Barroso L.A. [The Tail at Scale](#) (2013)

Устойчивость к росту задержки


Fault-tolerant techniques were developed because guaranteeing fault-free operation became infeasible beyond certain levels of system complexity. Similarly, **tail-tolerant techniques** are being developed for large-scale services because eliminating all sources of variability is also infeasible.

Dean J., Barroso L.A. [The Tail at Scale](#) (2013)

Стратегии борьбы с ростом задержки

- На уровне отдельных запросов
 - Ждать ответы на подзапросы до таймаута и выдавать возможно неполный ответ
 - Отправка дублирующего подзапроса после таймаута (hedged requests)
 - Отправка дублирующих подзапросов с быстрой отменой (tied requests)
- На уровне системы в целом
 - Разбиение данных на мелкие порции и их динамическое назначение на машины
 - Дополнительная репликация горячих порций данных
 - Временное исключение медленных машин из обработки запросов

Распределенный поиск (+репликация)



Параллельная обработка данных на кластере

Проблемы

- Требуется хранить и обрабатывать все больше данных
- Современные задачи намного превышают возможности одной машины
- Данные нельзя разместить полностью в памяти
- Данные хранятся и обрабатываются в отдельных системах
- Отказы в больших распределенных системах становятся нормой
- Реализовывать обработку данных в таких системах очень сложно
 - Требуются удобные высокоуровневые модели программирования
 - Требуются универсальные и масштабируемые среды выполнения

Typical New Engineer



- Never seen a petabyte of data
- Never used a thousand machines
- Never **really** experienced machine failure

Our software has to make them successful.



Web Search

- Сбор содержимого Web (crawling)
 - offline, загрузка большого объема данных, выборочное обновление, обнаружение дубликатов
- Построение инвертированного индекса (indexing)
 - offline, пакетные (batch) задания, периодическое обновление
 - обработка большого объема данных, предсказуемая нагрузка
- Ранжирование документов для ответа на запрос (retrieval)
 - online, интерактивные запросы, задержка ~10-100 миллисекунд
 - большое число клиентов, пики нагрузки

Построение индекса

- Исходные данные и требуемый результат

$[(id, content) \dots] \rightarrow [(term, [<id,tf> \dots]) \dots]$

- Извлечение слов из каждого документа

$(id, content) \rightarrow [(term1, <id,tf1>), (term2, <id,tf2>) \dots]$

- Группировка промежуточных данных для каждого слова

$[(term1, <id1,tf1>), (term1, <id2,tf2>) \dots] \rightarrow (term1, [<id1,tf1>, <id2,tf2> \dots])$

- Агрегация результатов для каждого слова

$(term, [<id1,tf1>, <id2,tf2> \dots]) \rightarrow (term, top_documents_for_term)$

Модель программирования MapReduce

- Базовой структурой данных являются пары (*ключ, значение*)
- Программа описывается путем определения функций

$$\text{map}: (k1, v1) \rightarrow [(k2, v2)]$$

$$\text{reduce}: (k2, [v2]) \rightarrow [(k3, v3)]$$

- На практике чаще всего

$$\text{reduce}: (k2, [v2]) \rightarrow (k2, v3)$$

Вычисление частот встречаемости слов

```
1: class MAPPER
2:     method MAP(docid  $a$ , doc  $d$ )
3:         for all term  $t \in \text{doc } d$  do
4:             EMIT(term  $t$ , count 1)

1: class REDUCER
2:     method REDUCE(term  $t$ , counts  $[c_1, c_2, \dots]$ )
3:          $sum \leftarrow 0$ 
4:         for all count  $c \in \text{counts } [c_1, c_2, \dots]$  do
5:              $sum \leftarrow sum + c$ 
6:         EMIT(term  $t$ , count  $sum$ )
```

Другие примеры

- Поиск в тексте (grep)

```
map:    (docid, content) → [(docid, line)]  
reduce: нет
```

- Группировка и сортировка по ключу

```
map:    (key, record) → (key, record)  
reduce: (key, [record]) → (key, [record])
```

- Анализ посещаемости сайта

```
map:    (logid, log) → [(url, visit_count)]  
reduce: (url, [visit_count]) → (url, total_count)
```


Другие примеры (2)


- Вычисление ключевых слов по сайтам

```
map:    (docid, <url, content>) → (hostname, doc_term_vec)
reduce: (hostname, [doc_term_vec]) → (hostname, host_term_vec)
```


- Обращение Web-графа (кто ссылается на страницу?)

```
map:    (docid, content) → [(url, docid)]
reduce: (url, [docid]) → (url, [docid])
```

Параллелизм по данным




Распараллеливание построения индекса



Дополнительные функции

- *partition*: $(k2, num_reducers) \rightarrow reducer_id$
 - Определяет распределение промежуточных данных между reduce-процессами
 - Пример: $hash(k2) \bmod num_reducers$
- *combine*: $(k2, [v2]) \rightarrow [(k2', v2')]$
 - Осуществляет локальную агрегацию промежуточных данных после *map* в рамках одного map-процесса
 - Для ассоциативных и коммутативных операций может использоваться *reduce*
- *compare*: $(k2, k2') \rightarrow \{-1, 0, 1\}$
 - Определяет отношение порядка между промежуточными ключами
 - Управляет сортировкой и порядком ключей в результирующих данных

Полная схема вычислений




MapReduce

- Модель программирования для описания процедур обработки данных
- Среда выполнения (runtime) для параллельной обработки больших объемов данных на кластере
- Программная реализация (Google, Hadoop, Spark, YTsaurus...)

Google MapReduce

- MapReduce: Simplified Data Processing on Large Clusters
(Jeffrey Dean, Sanjay Ghemawat)
 - 2004: [оригинальная статья на OSDI'04](#)
 - 2008: [статья в Communications of the ACM](#)



<https://habr.com/ru/articles/432324/>


Инфраструктура Google (2000-е)

- Кластеры из бюджетных серверов
 - PC-class motherboards, low-end storage/networking
 - Linux + своё ПО
 - Сотни тысяч машин, отказы являются нормой
- Распределенная файловая система GFS
 - Поблочное хранение больших файлов, write-once-read-many
 - Последовательные чтение и запись в потоковом режиме
 - Репликация блоков для отказоустойчивости
- Для хранения и обработки используются одни серверы
 - Перемещение вычислений дешевле перемещения данных
- Планировщик
 - Распределяет ресурсы кластера между приложениями



[Handling Large Datasets at Google: Current Systems and Future Directions](#) (Jeff Dean, 2008)

Google MapReduce



Мастер

- Управляет выполнением одного MapReduce-задания
- Запускает рабочие процессы на узлах кластера
- Распределяет map/reduce-задачи между рабочими процессами
- Хранит состояния всех задач (status, worker)
- Осуществляет координацию между map- и reduce-задачами
 - Получает информацию о файлах с промежуточными данными от map-задач
 - Передает эту информацию reduce-задачам
- Предоставляет информацию о статусе вычислений через HTTP-сервер

Оптимизации

- Локальность данных
 - Направлять map-задачи на узлы, хранящие требуемые данные или находящиеся рядом
- Локальная редукция данных
 - Выполнять после *map* функцию *combine*
- Совмещение операций
 - Загрузка и сортировка промежуточных данных
- Спекулятивное выполнение
 - В конце map- или reduce-фазы запустить оставшиеся задачи на нескольких узлах
 - Способ решения проблемы отстающих (т.н. stragglers)

Обработка отказов

- Сбой при выполнении задачи
 - Повторные попытки, пропуск плохих записей
- Отказ рабочего узла
 - Сбой аппаратуры, ПО или отзыв узла планировщиком
 - Определяется через периодические сообщения от рабочего (heartbeat)
 - Перезапуск map-задач: всех (выполненных и незавершенных), уведомление reduce-процессов
 - Перезапуск reduce-задач: только незавершенных
- Отказ мастера
 - Аварийное завершение MapReduce-программы

Семантика выполнения программы

- ...в присутствии отказов и спекулятивного выполнения
- Для детерминированных функций *map* и *reduce* гарантируется совпадение результата вычислений с результатом последовательного выполнения программы
- Для недетерминированных функций *map* и *reduce* гарантируется совпадение результата каждой reduce-задачи с результатом последовательного выполнения программы

Преимущества MapReduce

- Модель программирования
 - Высокий уровень абстракции за счет скрывания деталей организации вычислений
 - Позволяет разработчику сконцентрироваться на решаемой задаче
 - Легкость добавления новых стадий обработки данных
- Реализация
 - Автоматическое распараллеливание и распределение задач
 - Устойчивость к отказам
 - Масштабируемость

Недостатки MapReduce

- Глобальная синхронизация только между map и reduce
 - Задачи, требующие наличия общего состояния во время вычислений?
- Синхронизация между заданиями через файловую систему
 - Итеративные алгоритмы?
- Пакетная обработка больших порций данных
 - Интерактивный анализ данных?
 - Инкрементальное добавление небольших порций?
 - Online-обработка данных в потоковом режиме?

Материалы

- [Multicore and GPU Programming: An Integrated Approach](#) (глава 1)
- [Designing Distributed Systems: Patterns and Paradigms for Scalable, Reliable Services](#) (глава 7)
- [The Tail at Scale](#)
- [MapReduce: Simplified Data Processing on Large Clusters](#)
- [Data-Intensive Text Processing with MapReduce](#) (глава 2)
- [Web search for a planet: The Google cluster architecture](#)
- [The Google File System](#)
- [The Datacenter as a Computer](#)