

14. Устойчивость к произвольным отказам

Сухорослов Олег Викторович

16.12.2024

План лекции

- Произвольные (византийские) отказы
- Задача о византийских генералах
- Протокол Practical Byzantine Fault Tolerance (PBFT)
- Консенсус в сети Bitcoin

Произвольные (византийские) отказы

- Любое отклонение поведения частей РС от заданного протоколом
 - Наиболее общая модель отказов, включающая ранее рассмотренные
 - Процесс может быть активен, но при этом работать некорректно
- Намеренные атаки
 - Пропуск, вставка, изменение, повтор сообщений, сговор...
- Ненамеренные сбои
 - Сбои аппаратуры, баги в ПО...
 - [Shuttle Mission STS-124](#) (2008)
 - [Amazon S3 Availability Event](#) (2008)
 - [How the Boeing 737 Max Disaster Looks to a Software Developer](#) (2019)

Byzantine Generals Problem





Lamport L., Shostak R., Pease M. [The Byzantine Generals Problem](#) (1982)



Задача с командиром

- Главный генерал (командир) рассылает свой приказ (наступать, отступить) остальным генералам (лейтенантам)
- Требования
 - Все верные лейтенанты должны выполнить одинаковый приказ
 - Если командир не был предателем, то верные лейтенанты выполняют его приказ
- Предположения
 - Сообщения доставляются без изменений (контроль целостности)
 - Получатель может определить, кто отправил сообщение (аутентификация)
 - Отсутствие сообщения может быть определено (синхронная модель), в этом случае используется некоторое значение по умолчанию
- Сколько всего генералов N требуется в случае f предателей?

Три генерала (N=3, f=1)




Четыре генерала (N=4, f=1)



Алгоритм с устными сообщениями

- Алгоритм $OM(0)$
 1. Командир рассылает свое значение всем лейтенантам
 2. Каждый лейтенант использует полученное значение (или RETREAT, если ничего не получил)
- Алгоритм $OM(f)$
 1. Командир рассылает свое значение всем лейтенантам
 2. Пусть v_i – значение, которое лейтенант i получил от командира (или RETREAT, если ничего не получил). Лейтенант i запускает алгоритм $OM(f - 1)$, играя в нем роль командира и рассылая v_i остальным $N - 2$ лейтенантам.
 3. Пусть v_j – значение, которое лейтенант i получил от лейтенанта j ($j \neq i$) в результате алгоритма $OM(f - 1)$, или RETREAT, если ничего не получил. Лейтенант i использует значение детерминированной функции $majority(v_1, \dots, v_{N-1})$.

Семь генералов ($N=7, f=2$)




Алгоритм с устными сообщениями

- В случае f предателей требуется
 - не менее $3f + 1$ генералов
 - $f + 1$ раундов взаимодействий
 - $O(N^{f+1})$ сообщений
- Зависимость от таймаутов
 - уязвимость к атакам на корректные процессы (например, DoS)

Подписанные сообщения

- Сообщения подписаны отправителем
- Подпись верного генерала не может быть подделана
- Каждый генерал может проверить подпись и подлинность сообщения



Алгоритм с подписанными сообщениями

- Командир подписывает и отправляет свой приказ лейтенантам
- Лейтенант i ($i > 0$)
 - при получении сообщения $v\{0\}$ от командира и если он не получал приказов
 - сохраняет v в множестве $V_i : V_i = \{v\}$
 - подписывает и отправляет $v\{0, i\}$ остальным лейтенантам
 - при получении сообщения $v\{0, j_1, \dots, j_k\}$ и если v нет в V_i
 - добавляет v в V_i
 - если $k < f$, подписывает и отправляет сообщение $v\{0, j_1, \dots, j_k, i\}$ лейтенантам, которые еще не подписали сообщение
 - когда сообщений больше не ожидается, вычисляет финальный приказ с помощью функции $choice(V_i)$
- Сообщения, не прошедшие проверку подписей, отбрасываются

Алгоритм с подписанными сообщениями

- Требуется
 - не менее $f + 2$ генералов
 - $f + 1$ раундов взаимодействий
 - $O(N^{f+1})$ сообщений
 - можно уменьшить до $O(N^2)$

Консенсус

- Один или несколько процессов предлагают значения
- Алгоритм консенсуса определяет, какое из значений принять
- Требуемые свойства
 1. Каждый корректный процесс в конце концов принимает некоторое значение
 2. Если процесс принял значение v , то v было предложено некоторым процессом
 3. Никакой процесс не принимает значение дважды
 4. Никакие два процесса не должны принять разные значения
- Традиционные алгоритмы консенсуса (Paxos, Raft)
 - Не поддерживают произвольные отказы, только crash-recovery
 - Требуют не менее $2f + 1$ процессов

Консенсус с произвольными отказами

Свойства:

1. Каждый корректный процесс в конце концов принимает некоторое значение.
2. Если все корректные процессы предложили значение v , то ни один корректный процесс не примет значение отличное от v . В противном случае корректный процесс может принять только значение, предложенное некоторым корректным процессом, или специальное значение $\square$.
3. Никакой корректный процесс не принимает значение дважды.
4. Никакие два корректных процесса не должны принять разные значения.

Требуется не менее $3f + 1$ процессов

Practical Byzantine Fault Tolerance (PBFT)

- Castro M., Liskov B. [Practical Byzantine Fault Tolerance](#) (1999)
- Протокол для state machine replication на системе из N узлов-реплик
 - Репликация сервиса с состоянием и детерминированными операциями над ним
 - Клиенты отправляют запросы с операциями и ожидают ответов
- Предположения
 - Частично синхронная модель, ненадежные каналы... (см. предположения традиционных алгоритмов консенсуса)
 - Подлинность сообщений может быть проверена с помощью цифровых подписей
 - f реплик могут быть подвержены независимым произвольным отказам
- Требуется $3f + 1$ реплик для обеспечения требуемых свойств
 - Реплицированный сервис удовлетворяет линейизуемости (safety)
 - Клиенты в конце концов получают ответы на свои запросы (liveness)

РВFT: Оптимальность числа реплик


- Для ответа на запрос клиента должно быть достаточно получить ответы от $N - f$ реплик, так как f византийских реплик могут не ответить
- Но f реплик, от которых не пришли ответы, могут просто работать медленно, и среди ответивших опять же могут быть f византийских реплик
- Число ответов от корректных реплик в худшем случае $N - 2f$, при этом оно должно быть больше f , откуда получаем $N > 3f$

РВFT: Конфигурация системы

- Каждая реплика имеет идентификатор i от 0 до $N - 1$
- Конфигурация системы называется **view** (аналог эпохи в Raft)
- Внутри *view* одна из реплик является **главной (primary)**
 - принимает запросы от клиентов
 - присваивает им номера (sequence number) и рассылает по остальным репликам
 - определяется однозначным образом, например $i = view \bmod N$
- Остальные реплики играют роль **резервных (backup)**
 - принимают запросы от главной реплики
 - участвуют в процессе принятия решения о коммите операции
- При отказе главного реплики происходит смена *view*

РВФТ: Схема обработки запросов

- Клиент отправляет *подписанный* запрос главной реплике
- Главная реплика рассылает запрос резервным
- С помощью кворумов достигается консенсус относительно порядка выполнения запросов и их коммита
- Как только консенсус достигнут, реплики выполняют запрос и отправляют ответ напрямую клиенту
- Клиент ожидает получения $f + 1$ идентичных ответов от разных реплик
- Если клиент не дождался ответов, то он рассылает запрос всем репликам





РВФТ: Возможные проблемы


- Может отказать главная реплика
 - игнорирует запросы, назначает один номер разным запросам, пропускает номера...
 - резервные реплики отслеживают поведение главной и могут инициировать её смену
- Может отказать резервная реплика
 - некорректно сохраняет и применяет запросы, переданные корректной главной репликой
 - для защиты от таких отказов используются кворумы
- Реплика может отправить некорректный ответ клиенту
 - клиент ожидает получения $f + 1$ идентичных ответов от разных реплик

РВФТ: Основная идея


- Шаги протокола координируются с помощью т.н. **сертификатов**
 - Набор подписанных сообщений от кворума реплик, подтверждающих выполнение некоторого свойства
- Кворумы имеют размер $N - f = 2f + 1$
 - пересечение любых двух кворумов содержит хотя бы одну корректную реплику




РВFT: Протокол




PBFT: Write Request




PBFT: Шаг Pre-Prepare




PBFT: Шаг Prepare



PBFT: Шаг Commit



PBFT: War Response



Обнаружение отказа главной реплики

- Клиент не дожидается ответа на свой запрос
 - Или запрос клиента потерялся или главная реплика отказала
- После таймаута клиент рассылает запрос **всем** репликам
 - Реплика, которая уже закоммитила результат, отправляет его
 - Реплика, которая не получала *pre-prepare* от главной реплики, направляет запрос ей и ждёт прихода *pre-prepare*
 - Если реплика не получит *pre-prepare*, то главная реплика считается отказавшей
- В случае обнаружения отказа главной реплики, резервная инициирует изменение *view*
 - Номер *view* увеличивается на 1, определяется новая главная реплика
 - Реплика отправляет всем сообщение *view change*
 - Новая главная реплика вступает в права после получения $2f$ сообщений от других реплик

РВФТ: Детали

- Смена view
- Сборка мусора
- Восстановление отказавшей реплики
- Оптимизации

См. [статью](#)

РВFT: Свойства

- Операции упорядочены с помощью номеров *view* и *sequence number*
- Если корректная реплика закоммитила $[m, vn, sn]$, то никакая другая корректная реплика не может закоммитить $[m', vn, sn]$, где $m \neq m'$ и $D(m) \neq D(m')$
- Если клиент получил результат, то никакая корректная реплика не закоммитит другой результат
- Протокол в конце концов завершается (клиент получает результат)


PBFT: Недостатки

- Отказавшая главная реплика может замедлить работу протокола
 - Игнорирует изначальный запрос клиента
 - Отправляет *pre-prepare* только в ответ на повторный приход запроса от других узлов
- Ограниченная масштабируемость
 - Требуется $O(N^2)$ сообщений и взаимодействие каждый с каждым
- Не подходит для систем с открытым участием без изначального доверия
 - Самостоятельное подключение новых узлов
 - Защита от атаки Сивиллы (Sybil attack)

РВFT: Применение и развитие


- Permissioned (private) blockchains
 - [Hyperledger Sawtooth](#)
- Другие протоколы
 - Zyzzyva, Tendermint, HotStuff, LibraBFT...

Bitcoin



Nakamoto S. [Bitcoin: A peer-to-peer electronic cash system](#) (2008)

Цепочка блоков (blockchain)




Связь с SMR и консенсусом

- Репликация автомата (State Machine Replication)
 - Состояние – набор балансов счётов, блокчейн
 - Операции – транзакции между счётами, добавление блока
- Консенсус
 - Какие транзакции валидные и в каком порядке они выполнены
 - Какие блоки и в каком порядке включены в блокчейн
- Особенности
 - Децентрализованная система, нет регулирующего органа (authority)
 - Публичная система, каждый может подключиться, причем анонимно
 - Не все участники подключены друг к другу
 - Отсутствие взаимного доверия между участниками

Консенсус в Bitcoin

- Особенности
 - Рандомизация и вероятностные гарантии
 - Мотивация участников действовать честно путем вознаграждений в криптовалюте
- Базовый алгоритм
 - Новые транзакции рассылаются по всем узлам
 - Каждый узел собирает транзакции в новый блок
 - В каждом раунде выбирается **случайный** узел, который рассылает всем свой новый блок
 - Остальные узлы принимают блок, если все транзакции в нём валидны
 - Узлы подтверждают принятие блока путем включения его хеша в следующий создаваемый ими блок

Двойное расходование



Мотивация участников

- Наказать узел за то, что он создал "плохой" блок?
 - Нет, участники анонимны
- Поощрить узел за то, что он создал блок, попавший в стабильную ветвь блокчейна?
 - Да, у нас уже есть криптовалюта и её можно распределять анонимно
- Block reward
 - Создатель блока включает в него транзакцию с вознаграждением
 - Вознаграждение будет получено только, если блок попадет в стабильную ветвь
 - Сумма вознаграждения фиксированная и периодически уменьшается
- Transaction fee
 - Создатель транзакции может включить в неё "чаевые" за обработку

Как выбрать тот случайный узел?

- Требования
 - Создание блока не должно быть легким
 - Надо защититься от атаки Сивиллы
- Proof-of-work
 - Выбор узла пропорционально доступному его *владельцу* ресурсу (вычислительной мощности)
 - Для создания блока узел должен решить **hash puzzle** – найти значение *nonce*, такое что
$$H(\textit{nonce} || \textit{prev_hash} || \textit{tx}_1 || \textit{tx}_2 || \dots || \textit{tx}_i) < \textit{target}$$
 - Значение *target* динамически подбирается так, чтобы среднее время между созданиями блоков было 10 минут
 - Поиск решения hash puzzle вычислительно сложен, а проверка – нет

Материалы

- [Distributed Systems: Principles and Paradigms](#) (разделы 8.2.5, 2.5.3, 5.4.5, 8.2.6, 9.4.2, 9.4.3)
- [Distributed Systems: Concepts and Design](#) (раздел 15.5)
- [Bitcoin and Cryptocurrency Technologies](#) (главы 1-2)
- [Byzantine Fault Tolerance, from Theory to Reality](#)
- [Bitcoin's Academic Pedigree](#)
- [The Saddest Moment](#)